


高能效低幻觉：让 Claw 帮你安心摸鱼

在 OpenClaw 中通过一些技巧，提升「严肃任务」的可靠性

ID : cafe3310	ROLE : Model Product Engineer (蚂蚁百灵模型团队)
EVENT : ClawCon Shanghai 2026	STATUS : LOCAL GATEWAY READY

高能效低幻觉：什么适合交给模型，什么不适合

The Jagged Frontier: Mapping Model Task Suitability



Demo: 非御三家模型的低幻觉交付

**视频演示：魔改版的 openclaw
进行黄金市场分析和投资风险揭示**

CONSTRAINT_01

隔离上下文。切断多余会话记忆，避免污染执行逻辑。


CONSTRAINT_02

剥离人格化设定。禁止拟人化情绪，降低发散性幻觉率。

CONSTRAINT_03

强制风险提示。执行涉及资产指令前，必须输出标准风控拦截。

别让一个旗舰模型干完所有事



Harness: 安全必须做在模型之外

Anti-Pattern: 依赖 Prompt 防御注入

System: 你是一个严谨的助手，严禁胡说八道，必须输出合法格式。

[PLACEHOLDER: A/B DEMO -
[PLACEHOLDER: A/B DEMO - PROMPT
INJECTION ATTACK (DEFENSE FAILURE)]

❌ 面对供应链投毒和复杂注入，
防御率极低。

Step 1: 模型输出 (Raw Output)

[PLACEHOLDER: GUARDRAIL CODE
DEMO - 正则校验 & 强类型沙箱]

Step 3: 执行层拦截/放行

✅ 支付级安全原则：外置硬编码
规则引擎，零信任动态防御。

给自家模型带货

[PLACEHOLDER:
OPENROUTER QR CODE]

ARCHITECTURE	MLA + Linear Attention 混合架构
EFFICIENCY	极高 Token 能效 (大幅降低吞吐成本)
BEHAVIOR	极低幻觉率 (宁可输出 None, 不造假字段)
USE_CASE	完美适配 OpenClaw 单网关 Task Sub-agent

不免费，但贼便宜。本周 OpenRouter 限时免费，扫码获取 API Key，立刻接入你的本地测试流。