


高能效低幻觉：让 Claw 帮你安心摸鱼

在 OpenClaw 中通过一些技巧，提升「严肃任务」的可靠性

ID : cafe3310	ROLE : Model Product Engineer (蚂蚁百灵模型团队)
EVENT : ClawCon Shanghai 2026	STATUS : LOCAL GATEWAY READY

高能效低幻觉：什么适合交给模型，什么不适合

The Jagged Frontier: Mapping Model Task Suitability



Demo: 非御三家模型的低幻觉交付

**视频演示：魔改版的 openclaw
进行黄金市场分析和投资风险揭示**

CONSTRAINT_01

隔离上下文。切断多余会话记忆，避免污染执行逻辑。

CONSTRAINT_02

剥离人格化设定。禁止拟人化情绪，降低发散性幻觉率。

CONSTRAINT_03

强制风险提示。执行涉及资产指令前，必须输出标准风控拦截。

别让一个旗舰模型干完所有事

A/B 对比：角色分工

A. Chat Agent (旗舰交互)

职责：意图理解、多轮对话、情绪交互

配置：高参数 / 旗舰级贵模型

特点：人格化、带情绪、重体验

VS

B. Task Sub-Agent (专业执行)

职责：纯净干活、高危结构化任务执行

优势：上下文干净，低发散（宁可报错，绝不造假 JSON）

特点：非人格化、纯指令、重结果

WHY & HOW: 为什么要做分离？

WHY（核心原因）：

1. 避免干扰：人格化上下文会污染执行任务，增加幻觉风险。
2. 确保精确：结构化任务需要绝对的指令遵循和确定性输出。
3. 成本优化：昂贵模型用于交互，高效模型用于批量执行。

HOW（实现途径）：

⚙️ 这一架构已可在 OpenClaw 上通过「自定义插件（Custom Plugin）」完成任务路由与模型分发。

Harness: 安全必须做在模型之外

A. Anti-Pattern: 依赖 Prompt 防御注入

System: 您是一个严谨的助手，严禁胡说八道，必须输出合法格式。

✗ 面对供应链投毒和复杂注入，防御率极低。

[PLACEHOLDER: A/B DEMO - PROMPT INJECTION ATTACK (DEFENSE FAILURE)]

B. 支付级安全原则：外置硬编码规则引擎

Step 1: 模型输出 (Raw Output)


[PLACEHOLDER: GUARDRAIL CODE DEMO - 正则校验 & 强类型沙箱]

Step 3: 执行层拦截 / 放行

✓ 外置硬编码规则引擎，零信任动态防御。

Why: 复杂的提示词注入可绕过 Skill 护栏

复杂的提示词注入攻击（例如多层嵌套、角色扮演、特殊编码）可以诱导模型忽略系统预设的安全指令，从而绕过基于 Prompt 的 Skill 护栏，直接执行恶意操作或输出非预期内容。



🔥 在 OpenClaw 上，可以通过自定义插件实现外部安全 Hariss。开发强制的、基于规则的硬编码防御（如正则校验、类型检查、沙箱），确保即使模型被注入，输出仍能被拦截和清洗。

OpenClaw 自定义插件可完美实现此外部防御层。

给自家模型带货

[PLACEHOLDER:
OPENROUTER QR CODE]

ARCHITECTURE	MLA + Linear Attention 混合架构
EFFICIENCY	极高 Token 能效 (大幅降低吞吐成本)
BEHAVIOR	极低幻觉率 (宁可输出 None, 不造假字段)
USE_CASE	完美适配 OpenClaw 单网关 Task Sub-agent

不免费，但贼便宜。本周 OpenRouter 限时免费，扫码获取 API Key，立刻接入你的本地测试流。